

Resumen

La aplicación de redes neuronales en el campo de reconomiento de voz siempre ha tenido diferentes enfoques, en este caso se presenta una de las aplicaciones mas básicas del mismo, la identificación de comandos simples de voz usando principalmente redes Conv1D usando la paquetería Keras en Python

¿Qué es una red Convolutacional de una dimension?

Una red neuronal convolutacional de una dimensión (Conv1D) es un tipo especial de red diseñada para el procesamiento de datos los cuales tienen una estructura secuencial. Cuenta con los siguientes componentes principales:

- **Kernel:** Ventana deslizante que extrae las características de los datos
- **Longitud del kernel:** Número de pasos temporales que cubre el filtro
- **Stride:** Cuantos pasos se desplaza el kernel
- **Padding:** Relleno usado para la preservación de las dimensiones

Matemáticamente la operación de una Conv1D es el siguiente. Para una señal de entrada x de longitud L y un kernel w de longitud K

$$y(i) = \sum_{j=0}^{K-1} x(i+j) \cdot w(j) + b$$

Donde

- $y(i)$: Valor de salida en la posición i
- $x(i+j)$: Valor de entrada en la posición $i+j$
- $w(j)$: Peso del kernel en la posición j
- b : Terminio de bias o sesgo

Procesamiento del audio

El sonido se puede interpretar como vibraciones en un medio, donde cada vibración se puede describir como una onda continua la cual sufre cambios de presión a lo largo del tiempo. Para la digitalización del sonido se realizan muestra de dicha onda en intervalos regulares de tiempo (8kHz, 16kHz, 44.1kHz) para su posterior reconstrucción, la cantidad de muestra realizadas definen la «calidad» del audio, de esta forma los audio digitales tienen la siguiente estructura.

[120, 135, 150, 100, 45, -20, -100, ...]




Figura 1: Onda del comando de voz «yes»

Los conjunto de muestras de voz consisten en 65,000 grabaciones de diferentes personas de aproximadamente 1 seg de duración de 8 comandos de voz diferentes, los cuales están grabados a 16kHz y fueron remuestrados a 8kHz ya que la gran mayoría de frecuencias relacionadas a voz están presentes en dicha escala.




Figura 2: Grafica de entrenamiento y prueba

Ademas de lo anterior se aplico un filtro para quitar grabaciones demasiado cortas. Posteriormente se dividió el conjunto de datos en dos grupos de entrenamiento (80 %) y validación (20 %).

Arquitectura del modelo

Usando la paqueteria de Keras es posible construir el modelo usado de la siguiente manera:

```
1 inputs = Input(shape=(8000,1)); conv = inputs
2 #Configuracion de las capas convolucionales
3 conv_configs = [(8, 13), (16, 11), (32, 9), (64, 7)]
4 # Capas convolucionales en un bucle
5 for filters, kernel_size in conv_configs:
6     conv = Conv1D(filters, kernel_size, padding='valid', activation='relu',
7                   strides=1)(conv)
8     conv = MaxPooling1D(3)(conv); conv = Dropout(0.3)(conv)
9 # Flatten y capas densas
10 conv = Flatten()(conv)
11 # Capas densas
12 dense_units = [256, 128]
13 for units in dense_units:
14     conv = Dense(units, activation='relu')(conv)
15     conv = Dropout(0.3)(conv)
16 outputs = Dense(len(labels), activation='softmax')(conv)
17 model = Model(inputs, outputs)
```

Donde el empleo de capas del tipo Conv1D es para el tratamiento de los datos de audio en busca de patrones en los audios, mientras que el empleo de capas del tipo densa es con el objetivo final de clasificar el audio como alguno de los comandos de voz. El entrenamiento del modelo fue el siguiente:

```
1 model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['
2 accuracy'])
3 es = EarlyStopping(monitor='val_loss', mode='min', verbose=1, patience=10,
4 min_delta=0.0001)
5 mc = ModelCheckpoint('best_model.keras', monitor='val_accuracy', verbose=1,
6 save_best_only=True, mode='max')
7 history=model.fit(x_tr, y_tr, epochs=100, callbacks=[es,mc], batch_size=32,
8 validation_data=(x_val,y_val))
```




Figura 3: Cantidad y tipo de datos

Referencias

- [1] Pai, A. (2025). Aravindpai/Speech-Recognition [Jupyter Notebook].
<https://github.com/aravindpai/Speech-Recognition> (Obra original publicada en 2019)